

Examen parcial - Parte Practica

Gerencia de Riesgos Financieros Instrumento: Micron Technology (MU)

Setup

```
if (!require("pacman")) install.packages("pacman")
pacman::p_load(quantmod, tseries, aTSA, forecast, lmtest, ggplot2, FinTS)
options(scipen = 999)
```

Descarga de precios y calculo de retornos

```
mu_xts <- getSymbols("MU", src = "yahoo",
                    from = "2024-08-31", to = "2026-09-04",
                    auto.assign = FALSE)
precio <- Ad(mu_xts)
colnames(precio) <- "MU"

autoplot(precio) +
  labs(title = "MU - precio de cierre ajustado", x = "Fecha", y = "USD")

retorno <- na.omit(diff(log(precio)))

autoplot(retorno) +
  labs(title = "MU - retorno continuo diario", x = "Fecha", y = "Retorno")

# Retornos oscilan alrededor de cero, sin tendencia -> ya estacionarios.
```

1. Estadísticas descriptivas de los retornos

```
media <- mean(retorno) #EL retonro promedio diario es de 0,475%
desv <- sd(retorno) #La volatilidad diaria es de 4,5% diario
minimo <- min(retorno) #La peor caída en un día fue de 17,65%
maximo <- max(retorno) #La mejor subida en un día fue de 17,64$
mediana <- median(retorno) #La mediana es de 0,345%

c(media = media, sd = desv, min = minimo, max = maximo, mediana = mediana)
```

media	sd	min	max	mediana
0.004755733	0.045021605	-0.176486734	0.176400829	0.003458632

2. Raíces unitarias sobre el precio

```
precio_num <- as.numeric(precio)

#Hacemos las pruebas de estacionariedad sobre la serie original:

#H0 = Hay raíz unitaria (no hay estacionariedad)
#H1 = No hay raíz unitaria (hay estacionariedad)
```

```

adf.test(precio_num)
pp.test(precio_num)

#Ya ADF y PP son suficientes, no rechazan H0, es decir hay raíz unitaria (no es
#no es estacionaria)

#kpss.test(precio_num, lag.short = FALSE) / solo la aplicamos si adf y pp se
#contradicen

#Procedemos con la primera diferenciación, y realizamos de nuevo las pruebas:
precio_diff <- diff(precio_num)

adf.test(precio_diff)
pp.test(precio_diff)

#Ambas coinciden y rechazan H0, ya la serie es estacionaria con d=1

```

Augmented Dickey-Fuller Test
alternative: stationary

Type 1: no drift no trend

	lag	ADF	p.value
[1,]	0	1.14	0.932
[2,]	1	1.37	0.956
[3,]	2	1.75	0.980
[4,]	3	1.23	0.943
[5,]	4	1.40	0.959
[6,]	5	1.66	0.976

Type 2: with drift no trend

	lag	ADF	p.value
[1,]	0	0.105	0.964
[2,]	1	0.290	0.977
[3,]	2	0.586	0.989
[4,]	3	0.179	0.970
[5,]	4	0.318	0.978
[6,]	5	0.523	0.986

Type 3: with drift and trend

	lag	ADF	p.value
[1,]	0	-1.76	0.678
[2,]	1	-1.61	0.742
[3,]	2	-1.40	0.832
[4,]	3	-1.68	0.712
[5,]	4	-1.57	0.760
[6,]	5	-1.42	0.822

Phillips-Perron Unit Root Test
alternative: stationary

Type 1: no drift no trend

	lag	Z_rho	p.value
	5	1.75	0.98

Type 2: with drift no trend

	lag	Z_rho	p.value
	5	0.619	0.98

```
Type 3: with drift and trend
lag Z_rho p.value
5 -4.88 0.816
```

Augmented Dickey-Fuller Test (serie diferenciada, d=1)
alternative: stationary

Type 1: no drift no trend

```
lag ADF p.value
[1,] 0 -24.4 0.01
[2,] 1 -19.0 0.01
[3,] 2 -11.8 0.01
[4,] 3 -11.1 0.01
[5,] 4 -10.9 0.01
[6,] 5 -10.8 0.01
```

Type 2: with drift no trend

```
lag ADF p.value
[1,] 0 -24.5 0.01
[2,] 1 -19.1 0.01
[3,] 2 -11.9 0.01
[4,] 3 -11.3 0.01
[5,] 4 -11.1 0.01
[6,] 5 -11.0 0.01
```

Type 3: with drift and trend

```
lag ADF p.value
[1,] 0 -24.5 0.01
[2,] 1 -19.2 0.01
[3,] 2 -12.0 0.01
[4,] 3 -11.4 0.01
[5,] 4 -11.2 0.01
[6,] 5 -11.2 0.01
```

Phillips-Perron Unit Root Test (serie diferenciada, d=1)
alternative: stationary

Type 1: no drift no trend

```
lag Z_rho p.value
5 -524 0.01
```

Type 2: with drift no trend

```
lag Z_rho p.value
5 -522 0.01
```

Type 3: with drift and trend

```
lag Z_rho p.value
5 -520 0.01
```

3. Modelo ARIMA sobre los retornos

```
r <- as.numeric(retorno)
modelo <- auto.arima(r, stepwise = FALSE)
modelo
coeftest(modelo)
```

#a. todos los coeficientes son significativos con un nivel de significancia del 10%

```
#b. Se necesitaron 2 rezagos de la parte autoregresiva, es decir retornos de sus propios
# dos valores pasados y 2 rezagos dela parte de media movil, es decir, errores de los
# ultimos 2 periodos.
```

```
Series: r
ARIMA(2,0,2) with non-zero mean
```

```
Coefficients:
          ar1          ar2          ma1          ma2          mean
        -1.8366   -0.9360    1.8743    0.9565    0.0047
s.e.      0.0363    0.0422    0.0280    0.0306    0.0020
```

```
sigma^2 = 0.001987:  log likelihood = 851.47
AIC=-1690.93   AICc=-1690.76   BIC=-1665.62
```

```
z test of coefficients:
```

	Estimate	Std. Error	z value	Pr(> z)
ar1	-1.8365908	0.0362866	-50.6086	< 0.0000000000000002 ***
ar2	-0.9359737	0.0421684	-22.1985	< 0.0000000000000002 ***
ma1	1.8742768	0.0280397	66.8580	< 0.0000000000000002 ***
ma2	0.9564557	0.0305720	31.2887	< 0.0000000000000002 ***
intercept	0.0047407	0.0019897	2.3826	0.01719 *

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

4. Validacion de supuestos del modelo

```
res <- residuals(modelo)
```

```
#Media cero (se cumple)
```

```
t.test(res)
```

```
#No autocorrelación (se cumple)
```

```
Box.test(res, lag = 10, type = "Ljung-Box")
```

```
#Homocedasticidad (no se cumple) -> Se aplica GARCH en escenarios de heterocedasticidad
```

```
Box.test(res^2, lag = 10, type = "Ljung-Box")
```

```
FinTS::ArchTest(res, lags = 10)
```

```
#normalidad (no se cumple) -> Es deseable que sea normal por facilidad de interpretación
#pero no daña el modelo.
```

```
jarque.bera.test(res)
```

```
One Sample t-test
```

```
data:  res
```

```
t = 0.0066306, df = 501, p-value = 0.9947
```

```
95 percent confidence interval:
```

```
-0.003879620  0.003905895
```

```
sample estimates:
```

```
mean of x
```

```
0.00001313737
```

Box-Ljung test

```
data: res
X-squared = 9.508, df = 10, p-value = 0.4847
```

Box-Ljung test

```
data: res^2
X-squared = 43.848, df = 10, p-value = 0.000003506
```

ARCH LM-test; Null hypothesis: no ARCH effects

```
data: res
Chi-squared = 29.051, df = 10, p-value = 0.001223
```

Jarque Bera Test


```
data: res
X-squared = 78.702, df = 2, p-value < 0.000000000000000022
```

5. Pronostico de los siguientes 5 periodos

```
pron <- forecast(modelo, h = 5)
pron
```

```
autoplot(pron) +
  labs(title = "MU - pronostico de retornos (5 periodos)", x = "Periodo", y = "Retorno")
#INTERPRETACIÓN 1ER pronóstico: Se pronóstica que en el periodo 503 el retorno sea de -0,65%
#Con un nivel de confianza del 95% se estima que el rango máximo y mínimo esté entre
#esté entre +8,09% y -9,38%.
```

MU - pronóstico de retornos (5 periodos)



	Point Forecast	Lo 80	Hi 80	Lo 95	Hi 95
503	-0.006458565	-0.06357847	0.05066134	-0.09381592	0.08089879
504	0.017421194	-0.03973971	0.07458210	-0.06999887	0.10484125
505	-0.008097928	-0.06532693	0.04913107	-0.09562214	0.07942628
506	0.016420727	-0.04089217	0.07373362	-0.07123178	0.10407323
507	-0.004727113	-0.06212275	0.05266853	-0.09250617	0.08305194