

Volatilidad bajo presión: MU y WDC en la ola de los semiconductores de memoria

Andrés Londoño

1. Introducción

Estimar bien la volatilidad de una acción no es un ejercicio puramente estadístico: de ahí sale directamente el tamaño del riesgo que asume un inversionista, cuánto capital debe reservar una mesa de trading para cubrir pérdidas, y qué tan ajustado (o exagerado) queda un pronóstico de Valor en Riesgo. Usar un método que reacciona demasiado lento a un choque real, o uno que sobrerreacciona a un solo día extremo, tiene consecuencias prácticas directas sobre la gestión del riesgo de un portafolio.

En este trabajo se comparan cinco formas de estimar la volatilidad de los retornos diarios de dos acciones del sector de semiconductores de memoria — Micron Technology (MU) y Western Digital (WDC) —: volatilidad histórica, volatilidad móvil, EWMA, ARMA-ARCH y ARMA-GARCH. El documento está organizado así: primero se describen las dos acciones y se analiza el comportamiento de sus precios y retornos diarios; luego se estima la volatilidad con cada uno de los cinco métodos, señalando ventajas y desventajas de cada uno; y finalmente se presentan las conclusiones, incluyendo el pronóstico a 5 días del retorno, la volatilidad, el Valor en Riesgo y la Pérdida Esperada de los modelos ARCH y GARCH.

2. Descripción de las acciones seleccionadas

Micron Technology (MU). Micron es un fabricante estadounidense de memorias semiconductoras (DRAM y NAND flash), que provee componentes de memoria para centros de datos, computadores, teléfonos y, cada vez más, infraestructura de inteligencia artificial. Cotiza en el Nasdaq. Fuente: precio de cierre ajustado diario descargado de Yahoo Finance.

Western Digital (WDC). Western Digital es un fabricante estadounidense de dispositivos de almacenamiento de datos, especializado en discos duros (HDD) para centros de datos y almacenamiento empresarial — el mismo sector de infraestructura de memoria/almacenamiento que Micron, pero con un producto distinto (almacenamiento magnético en vez de memoria de semiconductor). Cotiza en el Nasdaq. Fuente: precio de cierre ajustado diario descargado de Yahoo Finance.

Se escogieron estas dos acciones porque comparten el mismo ciclo de demanda (construcción de centros de datos e inteligencia artificial), pero con modelos de negocio distintos dentro de ese ciclo — lo que hace interesante comparar si su volatilidad se comporta de forma parecida o no.

```
acciones <- c("MU", "WDC")

precios <- quantmod::getSymbols(acciones, src = "yahoo",
                                from = "2023-12-31", to = "2026-08-31",
                                periodicity = "daily",
                                auto.assign = TRUE, warnings = FALSE) %>%
  purrr::map(~quantmod::Ad(get(.))) %>%
  purrr::reduce(merge.xts) %>%
  `colnames<-`(acciones)
```

```

retorno.mu <- TTR::ROC(precios$MU, type = "continuous", na.pad = TRUE) %>% na.omit()
retorno.wdc <- TTR::ROC(precios$WDC, type = "continuous", na.pad = TRUE) %>% na.omit()

```


3. Análisis de los Precios y de los Retornos Diarios

Se anuncian y muestran a continuación los precios de cierre ajustados de las dos acciones, del 2 de enero de 2024 al 28 de agosto de 2026 (666 observaciones diarias):

```

p.precio.mu <- forecast::autoplot(precios$MU) +
  labs(title = "Precio MU", x = "Fecha", y = "USD") +
  theme_light() + theme(panel.grid = element_blank())
p.precio.wdc <- forecast::autoplot(precios$WDC) +
  labs(title = "Precio WDC", x = "Fecha", y = "USD") +
  theme_light() + theme(panel.grid = element_blank())
p.precio.mu | p.precio.wdc

```




Las dos series de precios muestran una tendencia claramente alcista en el período, con MU pasando de niveles cercanos a los \$75 a superar los \$200 hacia el final de la muestra, y WDC con un comportamiento similar — consistente con el boom de demanda de memoria e infraestructura de IA que vivió el sector en este período. Ninguna de las dos series de precios se ve estacionaria a simple vista (tendencia visible), por lo que se trabaja con los retornos, no con los precios, para el resto del análisis.

```

p.ret.mu <- forecast::autoplot(retorno.mu) +
  labs(title = "Retornos diarios MU", x = "Fecha", y = "Retorno") +
  scale_y_continuous(labels = label_percent()) +
  theme_light() + theme(panel.grid = element_blank())
p.ret.wdc <- forecast::autoplot(retorno.wdc) +
  labs(title = "Retornos diarios WDC", x = "Fecha", y = "Retorno") +
  scale_y_continuous(labels = label_percent()) +
  theme_light() + theme(panel.grid = element_blank())
p.ret.mu | p.ret.wdc

```



```
desc.mu <- psych::describe(coredata(retorno.mu))
desc.wdc <- psych::describe(coredata(retorno.wdc))
tabla.desc <- rbind(MU = round(desc.mu[,c("mean", "sd", "median", "skew", "kurtosis", "min", "max")], 4),
                    WDC = round(desc.wdc[,c("mean", "sd", "median", "skew", "kurtosis", "min", "max")], 4))
kable(tabla.desc, caption = "Estadísticas descriptivas de los retornos diarios")
```

Table 1: Estadísticas descriptivas de los retornos diarios

	mean	sd	median	skew	kurtosis	min	max
MU	0.0037	0.0420	0.0031	-0.0079	2.6005	-0.1765	0.1764
WDC	0.0037	0.0378	0.0030	-0.1767	3.1539	-0.2017	0.1550

Los retornos de ambas acciones oscilan alrededor de cero sin ninguna tendencia visible — la media diaria es prácticamente 0 en las dos series (consistente con el hecho estilizado de retorno medio cercano a cero en alta frecuencia, ya visto en clase), con una desviación estándar diaria de alrededor de 4% en ambos casos. Las dos series muestran claramente **clusters de volatilidad**: hay tramos donde los retornos se mueven mucho más (por ejemplo, alrededor de eventos de resultados trimestrales o noticias del sector de IA) seguidos de tramos más calmados, en vez de una dispersión pareja en el tiempo. La curtosis de ambas series está por encima de la de una distribución normal (2.60 en MU y 3.15 en WDC, sobre una base de exceso de curtosis 0 para la normal), y WDC muestra además una asimetría negativa más marcada (-0.18 frente a -0.01 en MU) — las colas anchas y la asimetría negativa son otro hecho estilizado típico de retornos accionarios: las caídas grandes tienden a ser un poco más frecuentes o más extremas que las subidas grandes equivalentes.

4. Estimación de la Volatilidad

4.1 Volatilidad Histórica

```
calc_vol_hist <- function(retorno) {
  n <- nrow(retorno)
  v <- vector()
  for (i in 2:n) v[i-1] <- sd(retorno[1:i])
}
```

```

  xts(v, order.by = index(retorno)[-1])
}
vol.hist.mu <- calc_vol_hist(retorno.mu)
vol.hist.wdc <- calc_vol_hist(retorno.wdc)


```

Se anuncia y muestra a continuación la volatilidad histórica (ventana expansiva, acumulando toda la muestra disponible en cada punto) de las dos acciones:

```

p.hist.mu <- forecast::autoplot(vol.hist.mu) +
  labs(title = "Volatilidad histórica MU", x = "Fecha", y = "Volatilidad") +
  scale_y_continuous(labels = label_percent()) +
  theme_light() + theme(panel.grid = element_blank())
p.hist.wdc <- forecast::autoplot(vol.hist.wdc) +
  labs(title = "Volatilidad histórica WDC", x = "Fecha", y = "Volatilidad") +
  scale_y_continuous(labels = label_percent()) +
  theme_light() + theme(panel.grid = element_blank())
p.hist.mu | p.hist.wdc

```



Las dos series se estabilizan hacia el final del período (menos movimiento en la línea a medida que se acumulan más datos) — es justamente la principal limitación de este método: como cada nuevo dato pesa cada vez menos sobre el promedio acumulado, la volatilidad histórica reacciona muy lento a lo que pasa recientemente, y un choque de volatilidad de hace un año sigue pesando exactamente igual que el de ayer. Su ventaja es que es la forma más sencilla de calcular, sin necesidad de escoger ningún parámetro adicional.

4.2 Volatilidad Móvil

```

ventana <- 20
vol.movil.mu <- zoo::rollapply(retorno.mu, width = ventana, FUN = sd) %>% na.omit()
vol.movil.wdc <- zoo::rollapply(retorno.wdc, width = ventana, FUN = sd) %>% na.omit()


```

Se anuncia y muestra a continuación la volatilidad móvil (ventana de 20 días, aproximadamente un mes de trading):

```

p.mov.mu <- forecast::autoplot(vol.movil.mu) +
  labs(title = "Volatilidad móvil (20d) MU", x = "Fecha", y = "Volatilidad") +
  scale_y_continuous(labels = label_percent()) +
  theme_light() + theme(panel.grid = element_blank())
p.mov.wdc <- forecast::autoplot(vol.movil.wdc) +
  labs(title = "Volatilidad móvil (20d) WDC", x = "Fecha", y = "Volatilidad") +
  scale_y_continuous(labels = label_percent()) +
  theme_light() + theme(panel.grid = element_blank())
p.mov.mu | p.mov.wdc

```



A diferencia de la volatilidad histórica, la volatilidad móvil sí muestra picos y valles claros que van y vienen a lo largo de toda la muestra — reacciona mucho más rápido porque solo usa los últimos 20 días para cada punto, en vez de arrastrar toda la historia. La desventaja es la contraparte de esa ventaja: pierde por completo la memoria de cualquier evento anterior a esos 20 días, sin importar qué tan relevante haya sido.

4.3 EWMA

Se estima la volatilidad EWMA con dos valores de λ : el valor propuesto por RiskMetrics ($\lambda = 0.94$) y un valor calculado a partir del tamaño de la muestra ($\lambda = 1 - 2/(T + 1)$), para contrastar un λ que “olvida” con relativa rapidez contra uno mucho más cercano a 1 (casi no olvida).

```

lambda.riskmetrics <- 0.94
lambda.datos <- 1 - (2/(length(retorno.mu)+1))

ewma_sigma <- function(retorno, lambda) {
  e <- MTS::EWMAvol(retorno, lambda = lambda)
  xts(sqrt(e$Sigma.t), order.by = index(retorno))
}

sigma.ewma94.mu <- ewma_sigma(retorno.mu, lambda.riskmetrics)
sigma.ewma94.wdc <- ewma_sigma(retorno.wdc, lambda.riskmetrics)
sigma.ewmad.mu <- ewma_sigma(retorno.mu, lambda.datos)
sigma.ewmad.wdc <- ewma_sigma(retorno.wdc, lambda.datos)

```


El λ calculado a partir de los datos resultó en 0.997 — muy cercano a 1, por lo que se espera que se comporte casi como la volatilidad histórica (mucha memoria, poca reactividad), en contraste directo con $\lambda = 0.94$.

```
lbl.d <- paste0("lambda=", round(lambda.datos, 3))

df_series <- function(...) {
  args <- list(...)
  nombres <- names(args)
  purrr::map2_dfr(args, nombres, ~ tibble(fecha = index(.x), valor = as.numeric(.x), serie = .y))
}

d.ewma.mu <- df_series("lambda=0.94" = sigma.ewma94.mu, "d" = sigma.ewmad.mu) %>%
  mutate(serie = recode(serie, "d" = lbl.d))
d.ewma.wdc <- df_series("lambda=0.94" = sigma.ewma94.wdc, "d" = sigma.ewmad.wdc) %>%
  mutate(serie = recode(serie, "d" = lbl.d))

p.ewma.mu <- ggplot(d.ewma.mu, aes(x = fecha, y = valor, color = serie)) +
  geom_line() +
  labs(title = "EWMA MU", x = "Fecha", y = "Volatilidad", color = "") +
  scale_y_continuous(labels = label_percent()) +
  theme_light() + theme(panel.grid = element_blank(), legend.position = "bottom")
p.ewma.wdc <- ggplot(d.ewma.wdc, aes(x = fecha, y = valor, color = serie)) +
  geom_line() +
  labs(title = "EWMA WDC", x = "Fecha", y = "Volatilidad", color = "") +
  scale_y_continuous(labels = label_percent()) +
  theme_light() + theme(panel.grid = element_blank(), legend.position = "bottom")
p.ewma.mu | p.ewma.wdc
```



Se confirma justo lo esperado: con $\lambda = 0.94$ la línea es mucho más “nerviosa”, subiendo y bajando con cada choque reciente, mientras que con $\lambda \approx 0.997$ la línea es casi tan suave y lenta como la volatilidad histórica de la sección 4.1 — un λ tan cercano a 1 casi no le da ventaja alguna sobre el método histórico. La ventaja general de EWMA sobre los dos métodos anteriores es que, con un λ bien elegido (como 0.94), sí le da más peso a lo reciente sin perder por completo la memoria del pasado, como hace la volatilidad móvil. Su

desventaja, vista ya en clase, es que aunque el peso de un choque disminuye con el tiempo, ese olvido es gradual — el efecto de un choque grande persiste durante varios días antes de desaparecer del todo.

4.4 ARMA-ARCH

Antes de modelar la varianza, se ajusta primero un modelo para la media de los retornos.

```
f.arima.mu <- forecast::auto.arima(retorno.mu, d = 0)
f.arima.wdc <- forecast::auto.arima(retorno.wdc, d = 0)
f.arima.mu
```

```
## Series: retorno.mu
## ARIMA(0,0,0) with non-zero mean
##
## Coefficients:
##          mean
##          0.0037
## s.e.    0.0016
##
## sigma^2 = 0.001763: log likelihood = 1166.92
## AIC=-2329.85   AICc=-2329.83   BIC=-2320.85
```

```
f.arima.wdc
```

```
## Series: retorno.wdc
## ARIMA(0,0,0) with non-zero mean
##
## Coefficients:
##          mean
##          0.0037
## s.e.    0.0015
##
## sigma^2 = 0.001428: log likelihood = 1237.03
## AIC=-2470.06   AICc=-2470.04   BIC=-2461.05
```

`auto.arima()` encontró para las dos acciones un **ARIMA(0,0,0) con media distinta de cero** — es decir, ningún término autorregresivo ni de media móvil, solo una constante (NA para MU y NA para WDC). No hay estructura predecible más allá del retorno promedio — el mismo resultado que ya se había encontrado en clase con Amazon, y consistente con la teoría de eficiencia de mercado vista anteriormente. Por eso la parte de la media en los modelos ARCH y GARCH de aquí en adelante se especifica como `arma(0,0)` con media libre (`include.mean = TRUE`), sin ningún rezago autorregresivo ni de media móvil que estimar.

```
f.arch.mu <- fGarch::garchFit(formula = ~arma(0,0)+garch(1,0), data = retorno.mu,
                             trace = FALSE, include.mean = TRUE)
f.arch.wdc <- fGarch::garchFit(formula = ~arma(0,0)+garch(1,0), data = retorno.wdc,
                             trace = FALSE, include.mean = TRUE)
```

```
summary(f.arch.mu)
```

```
##
## Title:
```

```

## GARCH Modelling
##
## Call:
## fGarch::garchFit(formula = ~arma(0, 0) + garch(1, 0), data = retorno.mu,
##   include.mean = TRUE, trace = FALSE)
##
## Mean and Variance Equation:
## data ~ arma(0, 0) + garch(1, 0)
## <environment: 0x000001ee3564b5f0>
## [data = retorno.mu]
##
## Conditional Distribution:
## norm
##
## Coefficient(s):
##      mu      omega    alpha1
## 0.0046367 0.0014944 0.1502592
##
## Std. Errors:
## based on Hessian
##
## Error Analysis:
##      Estimate Std. Error t value      Pr(>|t|)
## mu      0.0046367  0.0015811   2.933      0.00336 **
## omega  0.0014944  0.0001027  14.549 < 0.0000000000000002 ***
## alpha1 0.1502592  0.0520376   2.888      0.00388 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Log Likelihood:
## 1177.08      normalized: 1.767388
##
## Description:
## Wed Sep 23 10:48:23 2026 by user: Andres Londoño P
##
##
## Standardised Residuals Tests:
##
##      Statistic      p-Value
## Jarque-Bera Test  R    Chi^2 182.8737566 0.0000000000000000
## Shapiro-Wilk Test  R      W    0.9695634 0.0000000001549751
## Ljung-Box Test    R    Q(10) 18.8294288 0.0424834523463795
## Ljung-Box Test    R    Q(15) 34.8703591 0.0025657034879273
## Ljung-Box Test    R    Q(20) 47.8525374 0.0004461345027643
## Ljung-Box Test    R^2  Q(10) 34.1378945 0.0001750222373149
## Ljung-Box Test    R^2  Q(15) 53.0609892 0.0000037669817806
## Ljung-Box Test    R^2  Q(20) 68.7205452 0.0000002942263809
## LM Arch Test      R    TR^2 30.5165269 0.0023332653690943
##
## Information Criterion Statistics:
##      AIC      BIC      SIC      HQIC
## -3.525767 -3.505491 -3.525808 -3.517911

summary(f.arch.wdc)

```

```

##
## Title:
## GARCH Modelling
##
## Call:
## fGarch::garchFit(formula = ~arma(0, 0) + garch(1, 0), data = retorno.wdc,
## include.mean = TRUE, trace = FALSE)
##
## Mean and Variance Equation:
## data ~ arma(0, 0) + garch(1, 0)
## <environment: 0x000001ee33996468>
## [data = retorno.wdc]
##
## Conditional Distribution:
## norm
##
## Coefficient(s):
##      mu      omega    alpha1
## 0.0038438 0.0011628 0.1946300
##
## Std. Errors:
## based on Hessian
##
## Error Analysis:
##      Estimate Std. Error t value      Pr(>|t|)
## mu      0.00384384 0.00140064   2.744      0.00606 **
## omega  0.00116279 0.00008384  13.869 < 0.0000000000000002 ***
## alpha1 0.19462997 0.06304265   3.087      0.00202 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Log Likelihood:
## 1249.808      normalized: 1.876589
##
## Description:
## Wed Sep 23 10:48:23 2026 by user: Andres Londoño P
##
##
## Standardised Residuals Tests:
##
##      Statistic      p-Value
## Jarque-Bera Test  R    Chi^2 388.2190518 0.0000000000000000
## Shapiro-Wilk Test  R    W      0.9530624 0.00000000000010040
## Ljung-Box Test    R    Q(10) 15.5311322 0.11386405845553804
## Ljung-Box Test    R    Q(15) 26.1245045 0.03673420826393625
## Ljung-Box Test    R    Q(20) 30.8007926 0.05787584734338269
## Ljung-Box Test    R^2  Q(10) 56.4301832 0.00000001705081420
## Ljung-Box Test    R^2  Q(15) 74.9290092 0.00000000058316885
## Ljung-Box Test    R^2  Q(20) 94.6846985 0.00000000001111833
## LM Arch Test      R    TR^2 46.3689621 0.00000599286612069
##
## Information Criterion Statistics:
##      AIC      BIC      SIC      HQIC
## -3.744168 -3.723892 -3.744208 -3.736312


```

En las dos acciones, α_1 resultó positivo y significativo (0.1503 en MU, $p=0.0039$; 0.1946 en WDC, $p=0.0020$), cumpliendo la restricción de no negatividad de la varianza. Sin embargo, al revisar la prueba de Ljung-Box sobre los residuales estandarizados al cuadrado (que prueba si queda heterocedasticidad sin explicar), en **ninguna de las dos acciones** el ARCH(1) logra eliminarla del todo en rezagos largos (Q(10) con $p=0.0002$ en MU y $p<0.0001$ en WDC) — con solo un rezago de memoria, el modelo no alcanza a capturar toda la persistencia real de la volatilidad de estas dos acciones.

```
sigma.arch.mu <- xts(f.arch.mu@sigma.t, order.by = index(retorno.mu))
sigma.arch.wdc <- xts(f.arch.wdc@sigma.t, order.by = index(retorno.wdc))
```

Se anuncia y muestra a continuación la volatilidad estimada por el ARCH(1) para las dos acciones:

```
p.arch.mu <- forecast::autoplot(sigma.arch.mu) +
  labs(title = "Volatilidad ARCH(1) MU", x = "Fecha", y = "Volatilidad") +
  scale_y_continuous(labels = label_percent()) +
  theme_light() + theme(panel.grid = element_blank())
p.arch.wdc <- forecast::autoplot(sigma.arch.wdc) +
  labs(title = "Volatilidad ARCH(1) WDC", x = "Fecha", y = "Volatilidad") +
  scale_y_continuous(labels = label_percent()) +
  theme_light() + theme(panel.grid = element_blank())
p.arch.mu | p.arch.wdc
```



La ventaja del ARCH(1) frente a los tres métodos anteriores es que ya es un modelo condicional propiamente dicho (con parámetros estimados por máxima verosimilitud, no un promedio arbitrario), que reacciona a los errores recientes al cuadrado. La desventaja, confirmada arriba con la prueba de heterocedasticidad, es que con un solo rezago no es suficientemente parsimonioso para capturar toda la persistencia real de la volatilidad — habría que agregar más rezagos, lo que complica el modelo y hace más difícil cumplir la restricción de no negatividad de todos los coeficientes a la vez.

4.5 ARMA-GARCH

```
f.garch.mu <- fGarch::garchFit(formula = ~arma(0,0)+garch(1,1), data = retorno.mu,
```

```

                                trace = FALSE, include.mean = TRUE)
f.garch.wdc <- fGarch::garchFit(formula = ~arma(0,0)+garch(1,1), data = retorno.wdc,
                                trace = FALSE, include.mean = TRUE)

summary(f.garch.mu)

##
## Title:
##   GARCH Modelling
##
## Call:
##   fGarch::garchFit(formula = ~arma(0, 0) + garch(1, 1), data = retorno.mu,
##     include.mean = TRUE, trace = FALSE)
##
## Mean and Variance Equation:
##   data ~ arma(0, 0) + garch(1, 1)
##   <environment: 0x000001ee3f5bbee0>
##   [data = retorno.mu]
##
## Conditional Distribution:
##   norm
##
## Coefficient(s):
##           mu           omega          alpha1          beta1
## 0.003584022  0.000050512  0.072883616  0.901254189
##
## Std. Errors:
##   based on Hessian
##
## Error Analysis:
##           Estimate  Std. Error  t value          Pr(>|t|)
## mu          0.00358402  0.00146432   2.448         0.014383 *
## omega        0.00005051  0.00002163   2.336         0.019510 *
## alpha1      0.07288362  0.01879262   3.878         0.000105 ***
## beta1       0.90125419  0.02378990  37.884 < 0.0000000000000002 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Log Likelihood:
## 1202.08    normalized:  1.804925
##
## Description:
##   Wed Sep 23 10:48:25 2026 by user: Andres Londoño P
##
##
## Standardised Residuals Tests:
##
##           Statistic          p-Value
## Jarque-Bera Test  R    Chi^2 165.2434529 0.000000000000000
## Shapiro-Wilk Test  R    W      0.9774022 0.00000001282804
## Ljung-Box Test    R    Q(10) 13.1757532 0.21401062881564
## Ljung-Box Test    R    Q(15) 23.3658480 0.07667510565910
## Ljung-Box Test    R    Q(20) 30.4296152 0.06318503127246
## Ljung-Box Test    R^2  Q(10)  4.2160646 0.93707393453060

```

```

## Ljung-Box Test      R^2  Q(15)      6.3407935 0.97343717493266
## Ljung-Box Test      R^2  Q(20)      8.4363632 0.98856427818267
## LM Arch Test        R    TR^2      4.8878211 0.96162112633475
##
## Information Criterion Statistics:
##      AIC      BIC      SIC      HQIC
## -3.597837 -3.570803 -3.597909 -3.587363

summary(f.garch.wdc)

##
## Title:
##  GARCH Modelling
##
## Call:
## fGarch::garchFit(formula = ~arma(0, 0) + garch(1, 1), data = retorno.wdc,
## include.mean = TRUE, trace = FALSE)
##
## Mean and Variance Equation:
## data ~ arma(0, 0) + garch(1, 1)
## <environment: 0x000001ee41364150>
## [data = retorno.wdc]
##
## Conditional Distribution:
## norm
##
## Coefficient(s):
##      mu      omega      alpha1      beta1
## 0.004381082 0.000030592 0.082681591 0.899500936
##
## Std. Errors:
## based on Hessian
##
## Error Analysis:
##      Estimate Std. Error t value      Pr(>|t|)
## mu      0.00438108 0.00122375  3.580      0.000344 ***
## omega   0.00003059 0.00001215  2.518      0.011810 *
## alpha1  0.08268159 0.01882114  4.393      0.0000112 ***
## beta1   0.89950094 0.02205917 40.777 < 0.0000000000000002 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Log Likelihood:
## 1303.312      normalized: 1.956925
##
## Description:
## Wed Sep 23 10:48:25 2026 by user: Andres Londoño P
##
##
## Standardised Residuals Tests:
##
##      Statistic      p-Value
## Jarque-Bera Test  R    Chi^2 723.3938246 0.0000000000000000
## Shapiro-Wilk Test  R    W      0.9603836 0.00000000000202482

```


```
## Ljung-Box Test      R      Q(10)      7.2643126 0.70027877122433280
## Ljung-Box Test      R      Q(15)      9.4703206 0.85167124580695330
## Ljung-Box Test      R      Q(20)     13.1281799 0.87181689351284253
## Ljung-Box Test      R^2    Q(10)      2.0352999 0.99606237681714371
## Ljung-Box Test      R^2    Q(15)      4.0600627 0.99753401659464380
## Ljung-Box Test      R^2    Q(20)      6.0897937 0.99877070091590947
## LM Arch Test        R      TR^2       2.3697507 0.99859199840683677
##
## Information Criterion Statistics:
##      AIC      BIC      SIC      HQIC
## -3.901838 -3.874804 -3.901910 -3.891364
```

El GARCH(1,1) sí logra capturar la heterocedasticidad que el ARCH(1) no pudo: la prueba de Ljung-Box sobre los residuales estandarizados al cuadrado ya no rechaza en ningún rezago probado ($Q(10)$ con $p=0.937$ en MU y $p=0.996$ en WDC). En las dos acciones β_1 resultó muy significativo y grande (0.9013 en MU, 0.8995 en WDC) — la suma $\alpha_1 + \beta_1$ da 0.974 en MU y 0.982 en WDC, ambos bien por debajo de 1 (modelos estables) pero con persistencia bastante alta — la volatilidad de estas dos acciones tarda en volver a su nivel de largo plazo una vez sube.

```
sigma.garch.mu <- xts(f.garch.mu@sigma.t, order.by = index(retorno.mu))
sigma.garch.wdc <- xts(f.garch.wdc@sigma.t, order.by = index(retorno.wdc))
```

Se anuncia y muestra a continuación la volatilidad estimada por el GARCH(1,1) para las dos acciones:

```
p.garch.mu <- forecast::autoplot(sigma.garch.mu) +
  labs(title = "Volatilidad GARCH(1,1) MU", x = "Fecha", y = "Volatilidad") +
  scale_y_continuous(labels = label_percent()) +
  theme_light() + theme(panel.grid = element_blank())
p.garch.wdc <- forecast::autoplot(sigma.garch.wdc) +
  labs(title = "Volatilidad GARCH(1,1) WDC", x = "Fecha", y = "Volatilidad") +
  scale_y_continuous(labels = label_percent()) +
  theme_light() + theme(panel.grid = element_blank())
p.garch.mu | p.garch.wdc
```




La ventaja de GARCH sobre ARCH es justamente esta: con solo dos parámetros (α_1 y β_1 , en vez de necesitar muchos rezagos) logra capturar mucha más persistencia de la volatilidad, porque el término $\beta_1\sigma_{t-1}^2$ le da memoria de su propia varianza pasada, no solo del último error al cuadrado. Su desventaja compartida con ARCH es que ninguno de los dos corrige la falta de normalidad de los residuales (Jarque-Bera sigue rechazando con fuerza en las cuatro combinaciones) — aunque, como ya se discutió en clase, ese es el supuesto menos crítico de los cuatro a validar.

Comparación de los cuatro métodos

```
d.comp.mu <- df_series("Histórica" = vol.hist.mu, "EWMA (lambda=0.94)" = sigma.ewma94.mu,
                      "ARCH(1)" = sigma.arch.mu, "GARCH(1,1)" = sigma.garch.mu)
d.comp.wdc <- df_series("Histórica" = vol.hist.wdc, "EWMA (lambda=0.94)" = sigma.ewma94.wdc,
                      "ARCH(1)" = sigma.arch.wdc, "GARCH(1,1)" = sigma.garch.wdc)

comp.mu <- ggplot(d.comp.mu, aes(x = fecha, y = valor, color = serie)) +
  geom_line() +
  labs(title = "Comparación de métodos - MU", x = "Fecha", y = "Volatilidad", color = "") +
  scale_y_continuous(labels = label_percent()) +
  theme_light() + theme(panel.grid = element_blank(), legend.position = "bottom")
comp.wdc <- ggplot(d.comp.wdc, aes(x = fecha, y = valor, color = serie)) +
  geom_line() +
  labs(title = "Comparación de métodos - WDC", x = "Fecha", y = "Volatilidad", color = "") +
  scale_y_continuous(labels = label_percent()) +
  theme_light() + theme(panel.grid = element_blank(), legend.position = "bottom")
comp.mu | comp.wdc
```



En las dos acciones se ve el mismo patrón: la línea de volatilidad histórica es la más plana y la más lenta en reaccionar; EWMA y GARCH se mueven de forma mucho más parecida entre sí, siguiendo de cerca los picos y valles reales del mercado; y ARCH(1) es la más “nerviosa” y ruidosa de las cuatro, con picos puntuales muy marcados que no siempre se sostienen — la contraparte visual de que, como ya se vio, le falta memoria para suavizar bien esos picos.

Pronóstico a 5 días: retorno, volatilidad, VaR y Pérdida Esperada

Con los modelos ARCH(1) y GARCH(1,1) ya ajustados, se pronostica el retorno y la volatilidad de los siguientes 5 días, y a partir de ahí se calcula el Valor en Riesgo (VaR) y la Pérdida Esperada (Expected Shortfall) al 95% de confianza, de forma paramétrica bajo el supuesto de normalidad:

$$VaR_{95\%} = -(\hat{r}_t + z_{0.05} \cdot \hat{\sigma}_t) \quad ES_{95\%} = -\hat{r}_t + \hat{\sigma}_t \cdot \frac{\phi(z_{0.05})}{0.05}$$

donde $\hat{r}_t$ y $\hat{\sigma}_t$ son el retorno y la volatilidad pronosticados, $z_{0.05} = -1.645$ el cuantil 5% de la normal estándar, y ϕ su función de densidad.

```
alpha <- 0.05
z <- qnorm(alpha)
phi_z <- dnorm(z)
var_calc <- function(mu, sigma) -(mu + z*sigma)
es_calc <- function(mu, sigma) -mu + sigma*(phi_z/alpha)

tabla_pronostico <- function(pred, activo, modelo) {
  data.frame(
    Activo = activo, Modelo = modelo, Periodo = 1:5,
    `Retorno pronosticado` = percent(pred$meanForecast, accuracy = 0.01),
    `Volatilidad` = percent(pred$standardDeviation, accuracy = 0.01),
    `VaR 95%` = percent(var_calc(pred$meanForecast, pred$standardDeviation), accuracy = 0.01),
    `Pérdida Esperada 95%` = percent(es_calc(pred$meanForecast, pred$standardDeviation), accuracy = 0.01),
    check.names = FALSE
  )
}

pred.arch.mu <- predict(f.arch.mu, n.ahead = 5, plot = FALSE)
pred.arch.wdc <- predict(f.arch.wdc, n.ahead = 5, plot = FALSE)
pred.garch.mu <- predict(f.garch.mu, n.ahead = 5, plot = FALSE)
pred.garch.wdc <- predict(f.garch.wdc, n.ahead = 5, plot = FALSE)

tabla_completa <- rbind(
  tabla_pronostico(pred.arch.mu, "MU", "ARCH(1)"),
  tabla_pronostico(pred.garch.mu, "MU", "GARCH(1,1)"),
  tabla_pronostico(pred.arch.wdc, "WDC", "ARCH(1)"),
  tabla_pronostico(pred.garch.wdc, "WDC", "GARCH(1,1)")
)
kable(tabla_completa, caption = "Pronóstico a 5 días: retorno, volatilidad, VaR y Pérdida Esperada (95%)")
```

Table 2: Pronóstico a 5 días: retorno, volatilidad, VaR y Pérdida Esperada (95%)

Activo	Modelo	Periodo	Retorno pronosticado	Volatilidad	VaR 95%	Pérdida Esperada 95%
MU	ARCH(1)	1	0.46%	3.88%	5.91%	7.53%
MU	ARCH(1)	2	0.46%	4.15%	6.36%	8.09%
MU	ARCH(1)	3	0.46%	4.19%	6.42%	8.17%
MU	ARCH(1)	4	0.46%	4.19%	6.43%	8.18%
MU	ARCH(1)	5	0.46%	4.19%	6.43%	8.19%
MU	GARCH(1,1)	1	0.36%	4.23%	6.60%	8.37%
MU	GARCH(1,1)	2	0.36%	4.23%	6.61%	8.38%

Activo	Modelo	Periodo	Retorno pronosticado	Volatilidad	VaR 95%	Pérdida Esperada 95%
MU	GARCH(1,1)	3	0.36%	4.24%	6.62%	8.39%
MU	GARCH(1,1)	4	0.36%	4.24%	6.62%	8.40%
MU	GARCH(1,1)	5	0.36%	4.25%	6.63%	8.41%
WDC	ARCH(1)	1	0.38%	3.43%	5.27%	6.70%
WDC	ARCH(1)	2	0.38%	3.73%	5.75%	7.31%
WDC	ARCH(1)	3	0.38%	3.79%	5.84%	7.43%
WDC	ARCH(1)	4	0.38%	3.80%	5.86%	7.45%
WDC	ARCH(1)	5	0.38%	3.80%	5.86%	7.45%
WDC	GARCH(1,1)	1	0.44%	4.81%	7.47%	9.48%
WDC	GARCH(1,1)	2	0.44%	4.80%	7.46%	9.46%
WDC	GARCH(1,1)	3	0.44%	4.79%	7.44%	9.44%
WDC	GARCH(1,1)	4	0.44%	4.78%	7.42%	9.42%
WDC	GARCH(1,1)	5	0.44%	4.77%	7.40%	9.39%

El retorno pronosticado es constante en los 5 períodos para los dos modelos (porque la parte de la media es solo una constante, sin estructura ARMA) — alrededor de 0.46% diario en MU y 0.38-0.44% diario en WDC, el mismo retorno promedio histórico de cada acción. Lo que sí cambia con el horizonte es la volatilidad: en el ARCH(1), la volatilidad pronosticada converge rápido hacia su nivel de largo plazo (en 2-3 días ya casi no cambia, por la poca memoria de este modelo); en el GARCH(1,1), el cambio de un día a otro es mucho más suave, reflejo directo de la alta persistencia ($\alpha_1 + \beta_1$ cercano a 1) ya comentada. El VaR y la Pérdida Esperada, al ser función directa de la volatilidad pronosticada, siguen el mismo patrón: WDC con GARCH termina siendo, de las cuatro combinaciones, la que arroja el peor escenario (Pérdida Esperada cercana al 9.4% a 5 días) — no porque WDC sea “más riesgosa” en el largo plazo (su volatilidad histórica es prácticamente igual a la de MU), sino porque el modelo arrancó el pronóstico desde un nivel de volatilidad condicional más alto en los últimos días de la muestra.

5. Conclusiones

Los cinco métodos usados en este trabajo forman, en el fondo, una progresión: volatilidad histórica y volatilidad móvil son los extremos opuestos (memoria total y sin reacción, contra memoria nula y mucha reacción); EWMA es un punto intermedio ajustable con un solo parámetro (λ); y ARCH/GARCH son los únicos que, además de estimarse formalmente por máxima verosimilitud, se pueden validar con una prueba estadística explícita de si les queda o no heterocedasticidad sin explicar. Esa prueba fue justamente la que separó a los dos modelos condicionales en este trabajo: el ARCH(1) no fue suficiente para ninguna de las dos acciones, mientras que el GARCH(1,1) sí capturó toda la persistencia de la volatilidad en ambos casos, gracias al término adicional que le da memoria de su propia varianza pasada.

MU y WDC, pese a compartir el mismo ciclo de demanda del sector de memoria/almacenamiento, mostraron una dinámica de volatilidad parecida en el largo plazo (ambas con una desviación estándar diaria de alrededor de 4%) pero con una persistencia condicional ligeramente mayor en WDC ($\alpha_1 + \beta_1 = 0.982$ frente a 0.974 en MU) — coherente con que WDC también mostró la asimetría negativa y la curtosis más marcadas de las dos acciones en la sección 3. Para efectos de gestión de riesgo a corto plazo (el pronóstico a 5 días de la sección 4.5), esa diferencia se traduce en un Valor en Riesgo y una Pérdida Esperada más altos para WDC que para MU en el momento específico analizado, un resultado que solo un modelo GARCH, y no la volatilidad histórica, permite anticipar con esa oportunidad.